


El byte-CNN no había que descartarlo: había que recalibrarlo

Platt scaling ajustado con solo 25 flujos etiquetados del día nuevo, y medido sobre el resto -que el calibrador no ve-. El F1 pasa de 0.333 a más de 0.97 en los cuatro pares colapsados, y el ECE de ~0.499 -el máximo posible- a menos de 0.03.



■ sin recalibrar ■ tras Platt con 25 etiquetas

Platt scaling: $\text{sigmoide}(A \cdot \logit(p) + B)$ ajustada sobre una muestra balanceada del día de test y aplicada al resto. Fuente: `scripts/zeek/cross_recalibration.py` -> `models/phase3_recalibracion_*.json`. Más etiquetas apenas mejoran, salvo en el par más difícil (20-02 -> 15-02: recall 0.9571 con 25 frente a 0.9997 con 1000). Recalibrar NUNCA perjudica: el par que ya funcionaba pasa de 0.9597 a 0.9999. El trabajo independiente Cross-Dataset Transformer-IDS (2026) documenta el mismo fenómeno y lo corrige igual, bajando su ECE de 0.25 a 0.06.